

AI Agent 学习路线图 · 一页纸

韩立 · 2026.09.21 · 对应 `_ref/ai-agent-book-README.md` 与 `_ref/LEARNING-zh.md` (均来自原仓库原文) · 配套 交互演示/Agent核心公式-上下文消融.html

① 这本书是什么 (事实, 非评价)

书名	《深入理解 AI Agent: 设计原理与工程实践》· 李博杰 著
仓库	github.com/bojieli/ai-agent-book · 49.5k star · Apache-2.0 完全免费 · 15 种语言
体量	10 章正文 (中文约 1MB ≈ 50 万字) + 109 个配套实验 + 思考题参考答案
核心公式	Agent = LLM + 上下文 + 工具; 进生产改写为 Agent = Model + Harness, Harness = 上下文管理 + 工具接口 + 约束 + 验证 + 纠正。后三项就是「能跑的 Demo」与「可靠产品」的那道沟。
官方落地建议	「第 1-5 章足以做出一个可用的 coding agent」

② 十章难度地图 (官方分级) + 你现在要不要读

章	主题	官方难度	一句话核心	你现在
1	AI Agent 入门	入门级	Agent = LLM + 上下文 + 工具; Harness 才是竞争力	✓ 现在读
2	上下文工程	入门级	全书最关键一章: 上下文决定能力上限, 前缀越稳缓存命中越高	✓ 现在读
3	用户记忆和知识库	进阶级	把上下文从单次会话延伸成跨会话积累的持久知识	✓ 接着你的 RAG 读
4	工具	进阶级	感知工具控信息量, 执行工具控风险; MCP 协议	△ 稍后
5	Coding Agent 与通用 Agent	高级	代码是「能创造新工具的工具」	△ 要较强编程能力
6	交互: 观察与动作空间扩展	高级	异步 / 语音 / Computer Use / 机器人	△ 需懂 HTTP+WebSocket
7	Agent 的评估	工程级	没有评估, 就分不清「设计带来的提升」和「随机波动」	△ 做项目时再读
8	模型后训练	专家级	SFT 记忆、RL 泛化; 数据与环境比算法更重要	✗ 跳过 (要训练机器)
9	Agent 的持续进化	应用级	从运行轨迹获得学习信号	△ 以后
10	多 Agent 协作	应用级	多 Agent 的每个决策都能在单 Agent 三要素里找到对应	△ 以后

③ 你现在的水平线 (对照书的前置要求)

书要求的前置	你的状态
能读懂并修改中等复杂度的 Python	🟡 正在路上 (这正是你主线在干的事)
用过 ChatGPT / Claude 类 LLM 产品	✅ 有
熟悉至少一款 AI 辅助编程工具	✅ 你就是这么学的
命令行 / Git / JSON / REST API 常识	✅ 大部分 (REST 待补)

结论: 第 1-2 章够得着; 第 3 章正好接上你已经做的 RAG。你已过关的东西: SQL JOIN · pytest (27 passed) · 哈希模式 (23/23) · 双指针 (25/25) · 朴素 RAG (Recall@1 87%)。—— 尤其那个 87%: 它就是你读第 3 章时现成的对照组。别人是空手读, 你是带着一条基线去读的。

④ 三条入口 + 推荐顺序

A · 书的官方起点 (推荐下一步) ✅ 已在你机器上实测跑通
第 1 章正文 + 实验 chapter1/context (一个系统性"上下文消融"实验)
零成本: 注册表里真的有 ollama, 且 requires_key=False; main.py 帮助原文写着「ollama 为本地免费」(主 README 的 provider 表没宣传它)。
实测结果: --provider ollama --model qwen2.5:3b → 注册 4 个

⑤ 三条实话 (省得你走弯路)

1. 这本书不是入门教材, 别想着按顺序啃完。
正文约 50 万字 + 109 个实验。官方"入门级"是相对有编程基础的人说的。
正确用法: 当成项目库 + 字典 —— 卡在哪查哪, 想做什么找对应实验。
2. 作者明说: 配套代码不用逐行读。
原话: 「本书的配套代码全部由 coding agent 根据书稿生成, 作者也不会逐行阅读。关键是把架构、核心组件和设计原则想清楚, 然后让 AI 去写代码.....」
—— 这条对你好消息: 你现在的学法 (我写你验 / 你写我审) 本来就对路。
3. 第 8 章直接跳过。
全书唯一需要机器学习与模型训练经验的一章; 而且你这台机器 8G 显存做不了训练, 投入产出比为零。

⑥ 本机环境清单 (我已实测)

项	状态
Python	3.13.9 ✅ 书要求 3.11-3.13
uv	0.11.13 ✅ 书推荐 uv (有锁文件, 环境可复现)
Ollama 模型	bge-m3 1.2G · qwen2.5:3b 1.9G ✅ qwen2.5:3b 支持工具调用 (我实测通过)

工具、模型自主调用 `calculate` → 答出 **2000** $((128+372)\times 4$ ，正确)。2 轮迭代，全程本地。

B • 接着你现有的活干

第 3 章 `sparse-embedding` (从零实现 BM25 稀疏检索)
+ `retrieval-pipeline` (稠密 + 稀疏 + 神经重排序 = 混合检索)
用途：把你自己的 **Recall@1 从 87% 往上提** —— 有数字可量，不是空谈。

C • 最省力，先建立直觉（已完成）

本地复刻实验 1-1 的消融思想，用你的 `qwen2.5:3b` 跑，零成本：
样例代码库 `/agent_上下文消融.py` · 卡片 交互演示 `/Agent核心公式-上下文消融.html`
实测结果：抽掉「工具定义」或「工具结果」，成绩从 **20/20** → **0/20**。

推荐顺序：C（已完成）→ A（建立整本书的骨架）→ B（回到自己的 RAG 上验证第 3 章）

理由：A 是作者指定的起点，先有骨架再挑章节才不会迷路；B 紧贴你手头正在做的事，学完立刻能验证。

磁盘	E: 剩 385G 
GPU	RTX 5060 Laptop 8G  日常已用 5.4G，只剩约 2.7G

显存这一条会咬人，务必记住

Ollama 默认给模型开 **32768** 的上下文，KV cache 白吃一大片显存。
实测后果：跑几十次后 runner 直接崩，报 `model runner has unexpectedly stopped`；**崩了之后模型还会继续“回答”，但全是垃圾**（每道题都答 23）—— 假数据比报错危险。
解法：请求里加 `"num_ctx": 4096`。加了之后 30 次突发调用零失败。

⑦ 两个必须知道的坑（我都实测撞过）

坑 1 • 书上 `--provider ollama` 在 Windows 上开箱即坏

注册表把 ollama 的地址写死成 `http://localhost:11434/v1`。但本机 `localhost` 解析到 `IPv6 ::1`，而 Ollama 的 `/v1` 在 `:::1` 上 **直接断开连接** (`WinError 10054 / APIConnectionError`)。
解法：跑之前设环境变量
`OLLAMA_BASE_URL=http://127.0.0.1:11434/v1`
(`curl http://localhost:11434/v1/models` 返回 200，所以很容易误判成“服务没问题”—— 但 `curl` 和 `httpx` 的解析路径不一样，别用 `curl` 的结果给 SDK 背书)

坑 2 • 书里有个 bug，会把真错误藏起来

`chapter1/context/agent.py` 只写了 `from openai import OpenAI`，**没有 `import openai`**，但异常处理里用了 `openai.APITimeoutError` → **一旦 API 出错，异常处理器自己先崩**，你看到的是 `NameError: name 'openai' is not defined`，真正的错误信息（上面那条 `IPv6` 连接失败）被完全掩盖。
我从 `_ref/` 的本地副本加了这一行（原仓库未改），加完才看到真错误。

⑧ 我还不确定的地方（诚实标注）

未验证：109 个实验里究竟有多少个真正适配 ollama。
已确证的是 **provider 注册表层面支持**，并且 **实验 1-1 实测跑通**；其余章节逐个是否适配，需要一个个试。

一个已知的坑先告诉你：书的 ollama 默认模型是 `qwen3:8b`（约 5G），
你的显存装不下 → 必须手动加 `--model qwen2.5:3b`。

未验证：实验 1-1 里那个 `parse_pdf`（读 PDF）和 `code_interpreter`（跑代码）两个工具，在 `qwen2.5:3b` 上表现如何 —— 我只跑通了 `calculate` 这条路径。

资料来源：github.com/bojieli/ai-agent-book 的 `README.md`、`docs/zh-CN/LEARNING.md`、`chapter1-3/README.md`、`agentbook/providers/registry.py`、`chapter1/context/main.py`（均为 2026-09-21 读取的仓库原文）
本机实测数字来自 样例代码库 `/_run-agent消融.txt`（100 次模型调用，5 次重复 × 4 题 × 5 组）